

TP1: Réduction de dimension et clustering

27 Février 2026

Dans ce premier TP, nous étudierons la réduction de dimension et le clustering. Le langage de programmation utilisé est **Python**. La création d'un **environnement virtuel** est fortement encouragée (<https://docs.python.org/fr/3/tutorial/venv.html>). Nous utiliserons la bibliothèque **scikit-learn** (<https://scikit-learn.org/stable/>) pour les différentes implémentations des algorithmes vus en cours. Pour la création de graphiques, la bibliothèque **matplotlib** (<https://matplotlib.org/>) sera utilisée.

Configuration de l'environnement de travail

- Installer Python sur votre machine personnelle (si ce n'est pas déjà fait)
- Créer un environnement virtuel nommé *TP_VD*
- Dans l'environnement virtuel *TP_VD*, installer *scikit-learn*, *matplotlib*, *jupyter-lab*. Vous pouvez vous passer de jupyter-lab, mais vous devrez créer et/ou modifier des scripts Python à chaque manipulation. Pour l'installation des bibliothèques, privilégiez **pip**. Consulter les documentations (et faites appel à votre chargée de TP ;-)) au besoin.

Réduction de dimension

1. Charger le jeu de données digits en utilisant la fonction *load_digits* de *sklearn.datasets*. Récupérer également les étiquettes (classes/clusters) du jeu de données. Stocker les étiquettes dans une variable *y* et les observations dans une variable *X*. Quelle est la taille de ce jeu de données et son nombre de dimensions ? Hint : utiliser l'attribut *shape*.
2. Appliquer la PCA (deux composantes) sur le jeu de données digits
3. Afficher le résultat de la PCA précédente en utilisant matplotlib. Servez-vous des étiquettes pour afficher des chiffres identiques avec une couleur identique.
4. Comment trouvez-vous les groupes obtenus ? Sont-ils bien séparés ?
5. Appliquer *t*-SNE sur le jeu de données (2 composantes). Faire varier la **perplexité** (nombre de voisins). Afficher les résultats de *t*-SNE en utilisant matplotlib. Servez-vous des étiquettes pour afficher des chiffres identiques avec une couleur identique.
6. Comment trouvez-vous les groupes obtenus ? Sont-ils bien séparés ?

Clustering

1. Appliquer les *k*-means (avec *k* = 10) et DBSCAN sur les résultats des questions 2 et 5. Comparer les Adjusted Rand Index (ARI) obtenus dans chaque cas. Rappel : les vraies

étiquettes sont fournies par y . L'ARI est donné par la fonction *adjusted_rand_score* de *sklearn.metrics*

2. Visualiser les résultats des clustering.

Cette fois, nous générons des données. Générer le jeu de données contenant deux cercles concentriques. Générer ce jeu de données en utilisant la fonction *make_circles* de *sklearn.datasets*.

- 1.** Appliquer les k –means et DBSCAN sur le jeu de données.
- 2.** DBSCAN : faire varier ϵ . Que remarquez-vous ?
- 3.** Régénérer le jeu de données et augmenter progressivement le bruit. Appliquer DBSCAN à chaque augmentation du bruit.